

# Projet fil conducteur : Pipeline ETL Industrialisé

## 1. Présentation du Projet

### 1.1 Contexte et Objectifs


Ce projet de synthèse vise à concevoir et implémenter un pipeline ETL (Extract, Transform, Load) intégrant l'ensemble des compétences techniques acquises lors de votre formation. Le système doit permettre la collecte automatisée de données depuis diverses sources, leur transformation via des traitements distribués, et leur stockage dans une architecture moderne de type data lakehouse.

### 1.2 Périmètre Technique

- **Extraction** : Sources multiples (Site web, bases de données SQL, fichiers structurés)
- **Transformation** : Traitements distribués avec Apache Spark
- **Orchestration** : Planification et monitoring avec Apache Airflow
- **Stockage** : Solution object storage via MinIO (S3-compatible)
- **Industrialisation** : Conteneurisation, tests, documentation

## 2. Architecture Technique

### 2.1 Vue d'ensemble



## 3. Source de données

- Site web : <https://books.toscrape.com/>

- Fichier CSV :

[https://drive.google.com/file/d/1s-x76gQ-eoM5sqT2Hhcfn087Aw5D\\_hD/view?usp=sharing](https://drive.google.com/file/d/1s-x76gQ-eoM5sqT2Hhcfn087Aw5D_hD/view?usp=sharing)

Autres sources de données

## 4. Critères de Validation

### 4.1 Fonctionnels

- Extraction depuis au moins 3 sources différentes
- Transformation avec gestion des erreurs
- Chargement dans MinIO avec partitionnement
- Orchestration automatisée

- Gestion des reprises sur échec

## 4.2 Techniques

- Code versionné sur Git
- Tests avec couverture > 80%
- Configuration externalisée
- Logging structuré
- Monitoring des performances

## 4.3 Qualité

- Documentation complète
- Respect des conventions de code
- Gestion des secrets sécurisée
- Scripts de déploiement automatisés

# 5. Livrables Attendus

## 5.1 Code Source

- Dépôt Git contenant l'ensemble du code
- Configuration Docker fonctionnelle
- Scripts de déploiement et d'initialisation

## 5.2 Démonstration

- Exécution end-to-end du pipeline
- Présentation des métriques de performance
- Démonstration des capacités de monitoring